

академия
больших
данных


mail.ru
group



Сортировки и O-нотация

Шовкоплас Григорий

Введение в алгоритмы и структуры данных





Перед началом
использования



Правила курса

- Около 16 занятий
 - Лекция
 - Практика + ДЗ
- Экзамена не будет
- Оценка ставится в зависимости от процента сдачи домашних заданий
 - 50% — 3
 - 65% — 4
 - 80% — 5



Правила приема домашних заданий

- Контест на codeforces.com
- Около 4-6 задач
- Сдача задач:
 - Прислать ссылку на посылку в тестирующей системе на портале в соответствующей форме.
 - Проверяем код на адекватность (кодстайл, реализован нужный алгоритм и т.п.)
 - На ссылку ответ: зачтено или замечания
 - Soft deadline — среда 23:55
 - Гарантируется, что в течение четверга будет проверено
 - Hard deadline — пятница 23:55
 - После засчитываться не будет
- **Списывание и копирование чужого кода запрещено!**



Общая информация по сдаче задач


- Задача считается сданной, в тот момент, когда соответствующая ссылка отправлена
- Если есть одобрительная причина сдвинуть дедлайны, пишите об этом, мы готовы и хотим идти на встречу в таких ситуациях
- Для связи: Discord
- *NEW: Будет возможность сдать некоторые темы экстерном*



Алгоритмы и как их
оценивать

Что такое алгоритм?

- «Некоторая последовательность действий, приводящая к некоторому результату»
- Опустим многопоточность, откуда берутся входные данные и подобные усложнения



Пример алгоритма


Поиск максимума в массиве
натуральных чисел

input: Массив a длины n ,
состоящий из натуральных
чисел

```
res = 0
for i = 0 to n - 1
    if res < a[i]
        res = a[i]
print(res)
```


Как оценивать алгоритм?

- Время работы
 - Также полезно оценивать память, а иногда и другие параметры
- В секундах плохо
- Введем абстрактную модель
 - RAM-модель



- Оцениваем число элементарных операций RAM-модели
 - get, арифметические операции...

Оценка времени работы алгоритма

$T(n)$ — время работы алгоритма на входе размера n в худшем случае.

$$\begin{aligned} T(n) &= 5n + 2 \\ &= O(n) \end{aligned}$$

```
Finder
1: res = 0
2: for i = 0 to n - 1
3:   if res < a[i]
4:     res = a[i]
5: print(res)
```



O-нотация

- $T(n) = O(g(n))$
 - $\exists n_0, C = \text{const} : \forall n > n_0 \quad T(n) \leq C \cdot f(n)$
- $5n + 2 = O(n)$
 - $C = 10, n_0 = 2$
- $T(n) = \Omega(g(n))$
 - $\exists n_0, C = \text{const} : \forall n > n_0 \quad T(n) \geq C \cdot f(n)$



Сортировки



Сортировка вставками

- На k -ой итерации считаем, что первые k элементов отсортированы
- Ищем место для $k+1$ -го
- После n итераций все ОК

Сортировка вставками

Псевдокод

```
Finder
for i = 1 to n-1
  j = i
  while j > 0 and a[j - 1] > a[j]
    swap(a[j - 1], a[j])
    j--
```




Сортировка вставками

- Почему работает?
- Сколько работает?
 - 1, 2, 3, ... n
 - n, n-1, ... 2, 1
- $T(n) = O(n^2)$



Как применять оценку на практике

- $1\text{ГГц} = 10^9\text{с}^{-1}$
- 10^9 операций в секунду
 - каких операций?
- $n = O(n^2)$ следовательно при $n = 10^5$; $n^2 = 10^{10}$
- За секунду вряд ли работает
- **Оценка времени примерная!**



Сортировка
слиянием



Сортировка слиянием

- Пусть мы умеем за быстро сливать два отсортированных массива в один
- Разделяй и властвуй
 - Поделим массив на две части
 - Рекурсивно их отсортируем
 - Сольем в один
 - Done!

Слияние двух массивов

Псевдокод

```
merge(a, b)
  n = |a|
  m = |b|
  i = 0
  j = 0
  while i + j < n + m
    if j == m or (i < n and a[i] < b[j])
      c[i + j] = a[i]
      i++
    else
      c[i + j] = b[j]
      j++
  return c
```

Сортировка слиянием

Псевдокод

Хм.. чего-то не хватает...

```
merge_sort(a)
    n = |a|
    l = a[0..n/2-1]
    r = a[n/2..n-1]
    merge_sort(l)
    merge_sort(r)
    return merge(l, r)
```

Сортировка слиянием

Терминальное условие!

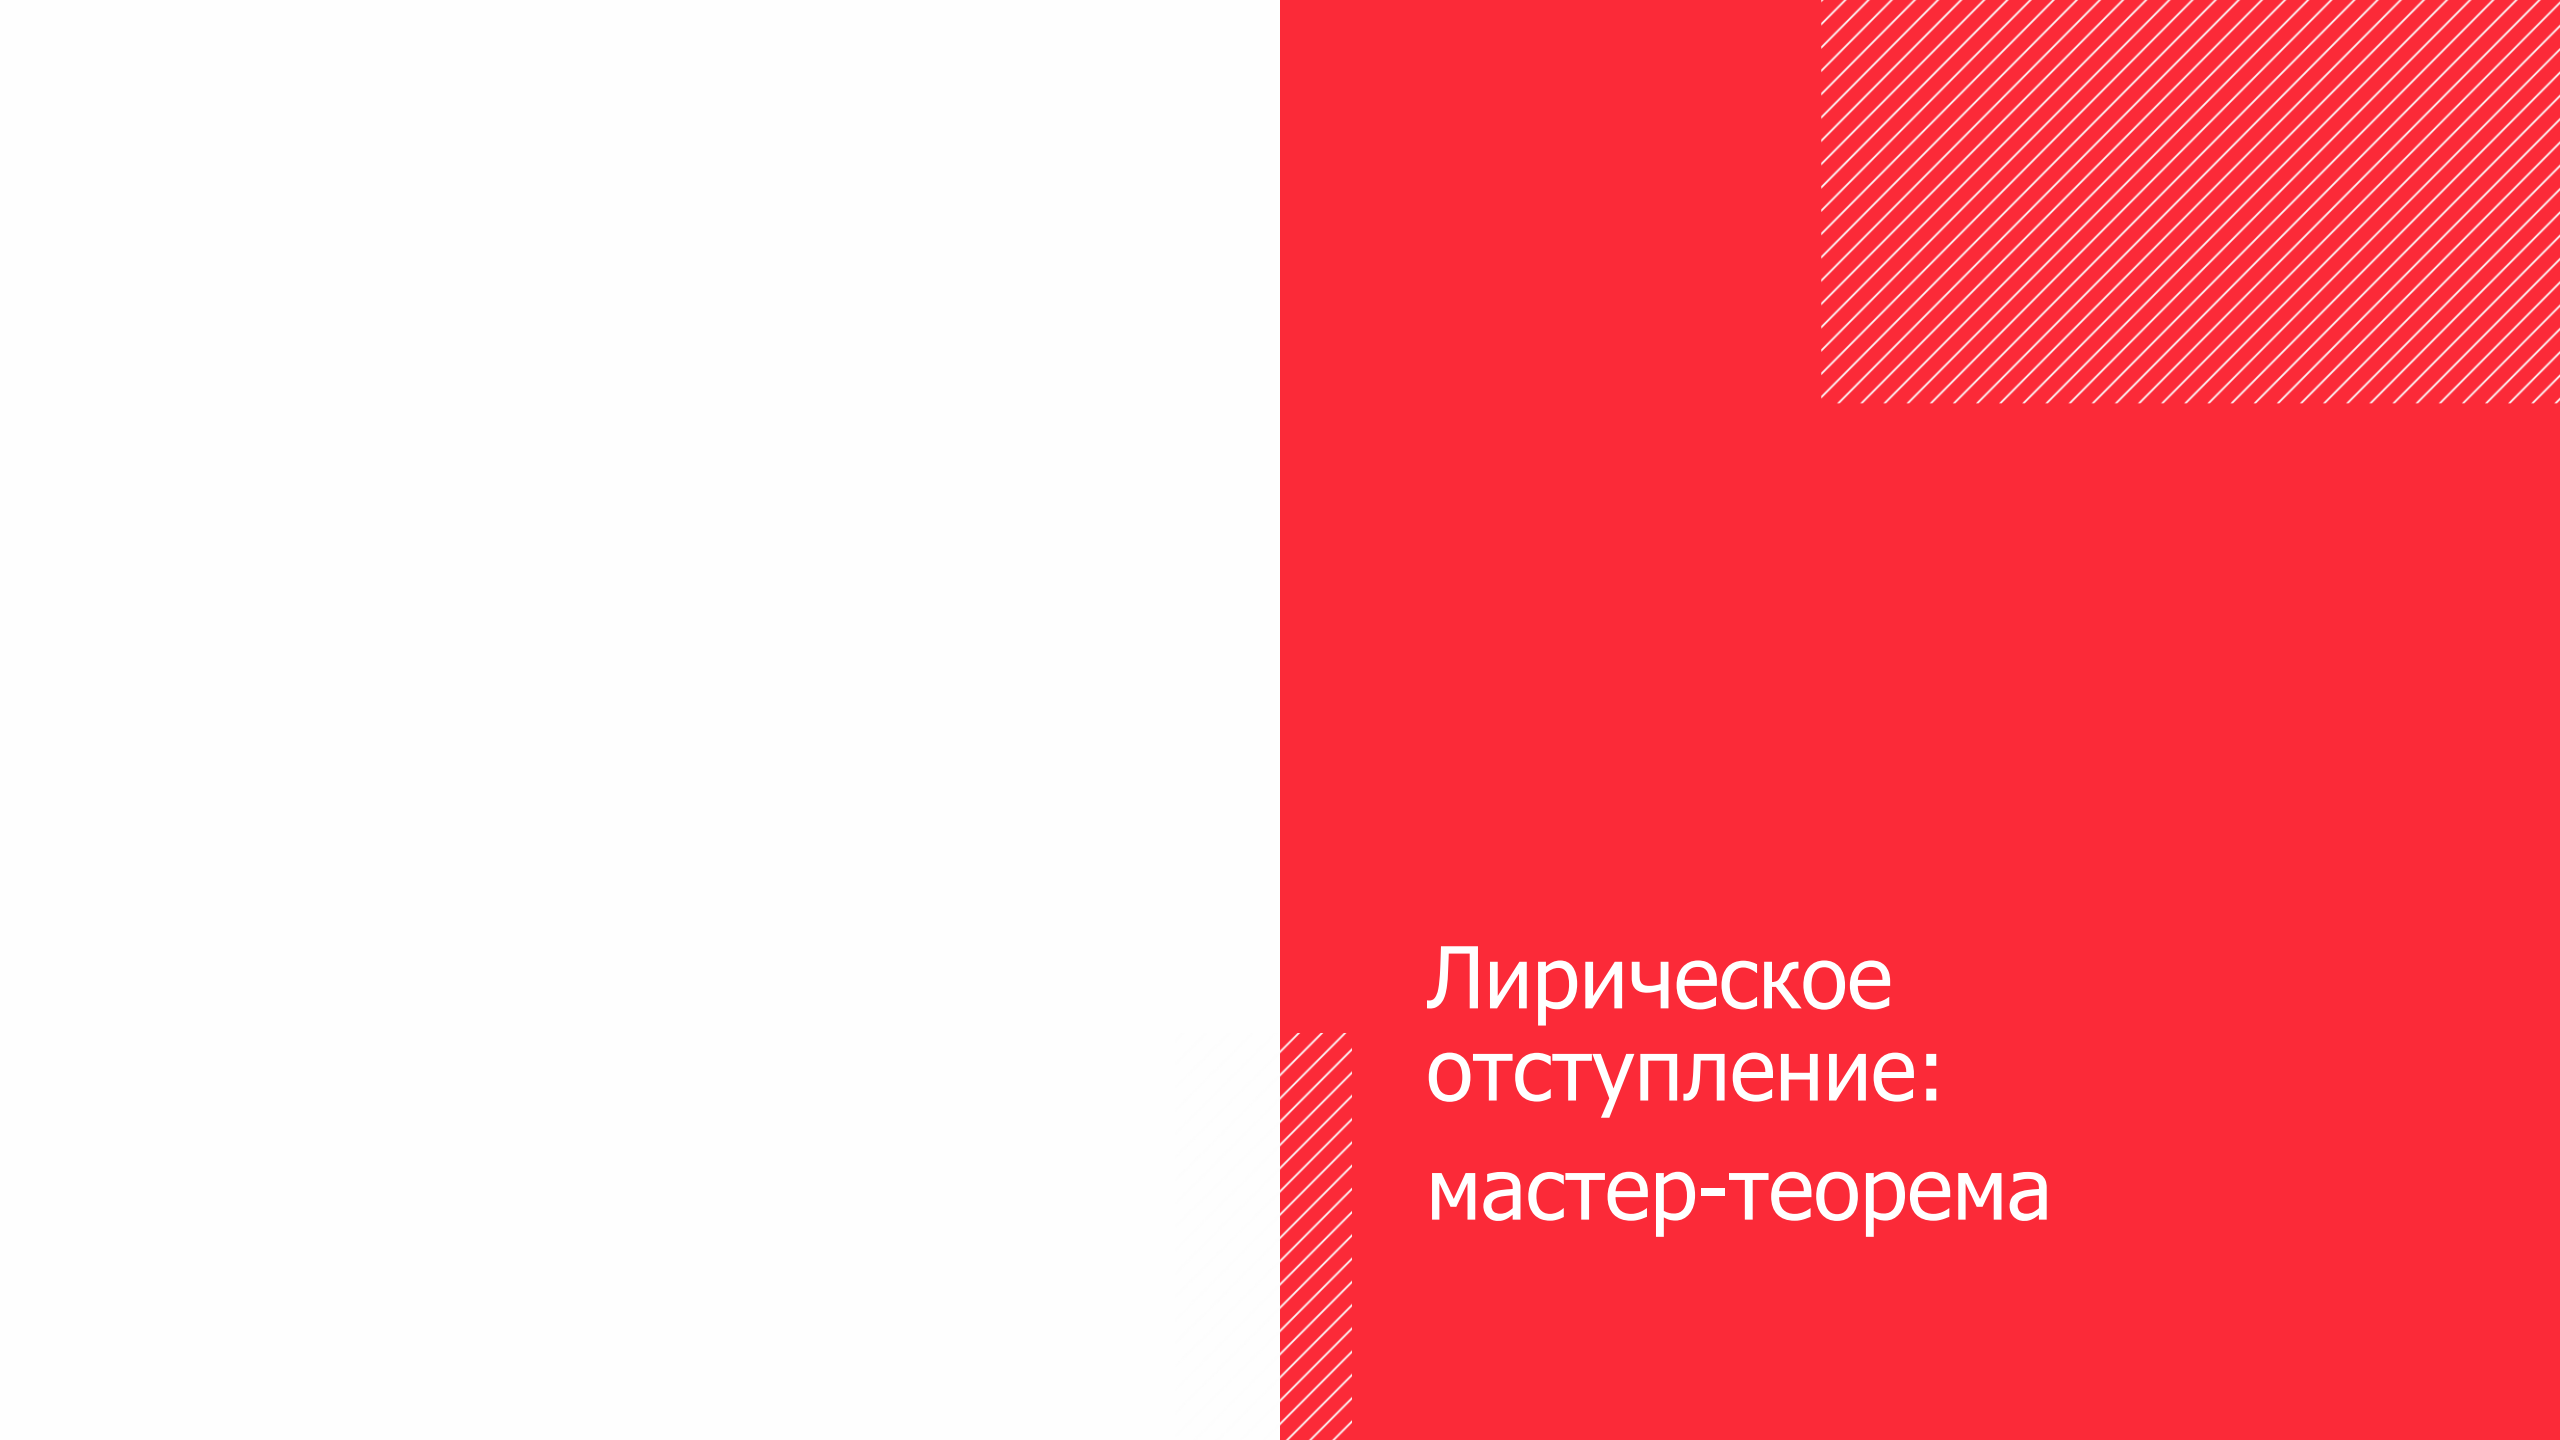
```
merge_sort(a)
    n = |a|
    if n = 1
        return a
    l = a[0..n/2-1]
    r = a[n/2..n-1]
    merge_sort(l)
    merge_sort(r)
    return merge(l, r)
```

Сортировка слиянием

Оценка времени работы:

- Графически
- Рекуррентно
 - «В лоб»
 - Математическая индукция

```
merge_sort(a)
    n = |a|
    if n = 1
        return a
    l = a[0..n/2-1]
    r = a[n/2..n-1]
    merge_sort(l)
    merge_sort(r)
    return merge(l, r)
```



Лирическое отступление: мастер-теорема

Мастер-теорема

- Пусть имеется рекуррентное соотношение:

- $$T(n) = \begin{cases} aT\left(\frac{n}{b}\right) + O(n^c), & n > 1 \\ O(1), & n = 1 \end{cases}$$

- $a \in \mathbb{N}, b \in \mathbb{R}, b > 1, c \in \mathbb{R}^+$

- Тогда асимптотическое решение имеет вид:

- Если $c > \log_b a$, то $T(n) = O(n^c)$


- Если $c = \log_b a$, то $T(n) = O(n^c \log n)$

- Если $c < \log_b a$, то $T(n) = O(n^{\log_b a})$



Свойства сортировки слиянием

- Требуется дополнительная память
- Устойчивость (стабильность)
- Работает всегда за $O(n \log n)$



Быстрая сортировка



Быстрая сортировка

- *Пусть все числа в массиве различны*
- Можем разделить на две части относительно некоторого числа x
 - $< x$
 - $> x$
- Отсортируем их рекурсивно
- Все ок?

Разделение массива

Псевдокод

```
split(a, x)
  l = []
  r = []
  for i = 0 to n-1
    if a[i] < x
      l.add(a[i])
    else
      r.add(a[i])
  return (l, r)
```

Разделение массива

Откажемся от
дополнительной памяти

Инвариант: элементы от l до m
меньше x

```
split(l, r, x)
    m = l
    for i = l to r-1
        if a[i] < x
            swap(a[i], a[m])
            m++
    return m
```

Быстрая сортировка

Псевдокод

```
qsort(l, r)
    if r - l <= 1
        return
    x = a[(l + r) / 2]
    m = split(l, r, x)
    qsort(l, m)
    qsort(m, r)
```



Оценка времени работы

- В худшем случае $O(n^2)$
 - Почему называется быстрой?
- Среднее время работы $O(n \log n)$
 - Почему?
- Дополним код

Быстрая сортировка

Псевдокод

```
qsort(l, r)
    if r - l <= 1
        return
    x = a[(l + r) / 2]
    x = a[rand(l..r-1)]
    m = split(l, r, x)
    qsort(l, m)
    qsort(m, r)
```




Свойства быстрой сортировки

- Не требуется дополнительная память
 - Не устойчива
 - В худшем случае $O(n^2)$
 - На практике работает быстрее сортировки слиянием (при адекватной реализации)
-
- Кстати, дополнительно нужно рассмотреть случай, если могут быть равные элементы



Bce!